

MODULE 06

## 어떤 모델이 "좋다"고 말할 근거

모델을 도입하려면 "써보니 괜찮더라"보다 나은 근거가 필요합니다. 이 모듈에서는 같은 문제지로 여러 모델을 채점하는 법, 그리고 무엇을 재야 하는지를 다룹니다.

### 01 인상이 아니라 측정

"써보니 괜찮던데"는 데모 몇 번을 해본 인상일 뿐입니다. 도입 근거로 쓰려면 같은 문제지로 여러 모델을 채점한 표가 있어야 합니다.

그 문제지가 **골든셋**입니다. 입력과 정답(모범 답)의 쌍을 모아둔 것으로, 50~100건 정도면 의미 있는 비교를 시작할 수 있습니다.

골든셋이 있으면 다음을 전부 같은 문제지로 확인할 수 있습니다.

- ✓ **모델 비교** — 후보 모델들의 성능을 같은 기준으로 나란히 비교합니다.
- ✓ **양자화 품질 확인** — 모듈 3에서 다룬 양자화가 품질을 얼마나 깎았는지 측정합니다.
- ✓ **프롬프트 개선의 전후 비교** — 프롬프트를 고치기 전과 후의 점수를 비교합니다.

### 02 민감 데이터 없이 평가하기 — 합성 데이터

평가하려면 실제 업무 데이터가 필요합니다. 그런데 실데이터에는 개인정보가 들어 있어서 그대로 쓸 수 없습니다.

해법은 실데이터의 분포(어떤 유형이 몇 %씩 섞여 있는지의 비율 구성), 즉 유형 비율·길이·난이도를 먼저 분석하고, 그 분포를 따르는 가짜 데이터를 LLM으로 생성하는 것입니다. 이것이 **합성 데이터**입니다.

### 실사례 — 합성 골든셋 (내부 사전 실증)

연구회의 내부 사전 실증에서는, 전년도 민원 통계에서 유형 분포를 뽑아내고 그 분포를 그대로 따르는 가상 민원 100건을 생성해 골든셋을 만들었습니다. 개인정보는 0건이지만, 실제 업무의 난이도는 그대로 반영되어 있습니다. 이 방법을 9월에 우리 공통 태스크에 그대로 적용해 볼 겁니다.

## 03 무엇을 재나 — 네 가지 지표

평가라고 다 같은 지표를 재는 것이 아닙니다. 태스크마다 중요한 지표가 다릅니다.

| 지표                | 뜻                | 이런 태스크에서 중요  |
|-------------------|------------------|--------------|
| 정답률(Accuracy)     | 정답과 일치하는 비율      | 분류·추출        |
| 근거성(Groundedness) | 주어진 근거에만 기반해 답했나 | RAG·요약       |
| 지연(Latency)       | 요청부터 응답까지 시간     | 대화형, 실시간 보조  |
| 처리량(Throughput)   | 단위 시간당 처리 건수     | 야간 배치, 대량 처리 |

야간 배치 처리에는 지연이 덜 중요하고, 실시간 보조 업무에는 지연이 결정적입니다. 지표를 하나만 보고 "이 모델이 좋다"고 말할 수 없는 이유가 여기에 있습니다.

## 04 환각 — 그럴듯한 거짓

모델은 모듈 2에서 본 것처럼 다음 토큰을 예측하는 프로그램입니다. 그래서 모르는 내용도 그럴듯하게 지어낼 수 있습니다. 이것을 **환각(hallucination)**이라고 부릅니다.

- ✓ **RAG로 근거를 준다** — 지어낼 필요를 애초에 줄입니다.
- ✓ **출력과 근거를 대조 검사한다** — 답이 근거 문서에 실제로 있는 내용인지 확인합니다.
- ✓ **기계 검증 가능한 부분은 게이트로 잡는다** — 숫자나 형식처럼 결정적으로 확인 가능한 부분은 게이트에서 걸러냅니다.

## 05 채점을 누가 하나 — 기계, 사람, 그리고 LLM 심판

채점에도 우선순위가 있습니다.

- ✓ ① **기계 채점** — 정답 일치, 정규식(010-####-#### 같은 글자 모양 규칙을 기계적으로 검사하는 방법입니다 — 처음 보는 말이면 [위밍업](#)에서 먼저 익히세요), 형식 검사처럼 결정적으로 확인 가능한 것부터 채점합니다.
- ✓ ② **LLM-as-judge** — 더 강한 모델에게 채점 기준표를 주고 채점을 맡깁니다. 요약 품질처럼 기계 채점이 어려운 항목에 씁니다.
- ✓ ③ **사람 검수** — 최종 확인 차원에서 일부를 샘플링(전체 중 일부만 무작위로 뽑아 확인)해 사람이 직접 봅니다.

LLM 심판을 쓸 때는 주의할 점이 있습니다. 반출이 허용된 데이터만 외부의 강력한 모델로 보내야 하고, 심판이 내린 결과도 다시 샘플링해서 사람이 재확인해야 합니다.

### 실측 교훈 (내부 사전 실증)

같은 민원 분류 사전 실증에서 품질 1위는 [thinking](#) 모델이었습니다. 하지만 건당 약 18초(일반 모델의 6배)에, 한 건은 65분까지 폭주하는 꼬리 리스크까지 있어 실무에는 쓸 수 없다는 판정을 받았습니다. 평가의 결론은 "가장 좋은 모델"이 아니라, "업무 요구(품질 기준과 시간 기준)를 만족하는 가장 가벼운 모델"을 고르는 것이어야 합니다.

### 🔗 우리 연구회에선

9월에는 공통 태스크 2개의 골든셋을 함께 만들고, 우리 서버 모델과 후보 모델들을 같은 문제지로 채점해서 '모델 선정 사유서'를 씁니다. 이 모듈은 그 실습을 위한 예습입니다.

### ↗ 심화 학습

평가 개념을 실습으로: [Hugging Face LLM Course](#) · 영어(일부 한국어 번역), 무료.

평가 사고방식의 뿌리(선택 심화): [Stanford CS229 — Machine Learning \(Andrew Ng, 공개 강의\)](#) · 영어(자막 지원). LLM 특화는 아니지만 "측정으로 판단한다"는 사고의 원류입니다.

## 이해했는지 확인해 봅시다

틀려도 괜찮습니다 — 오답을 고르면 왜 아닌지 설명이 나오고, 정답을 찾을 때까지 다시 고를 수 있습니다. 점수는 첫 시도 기준입니다.

문제 1 / 4

### Q1. 골든셋(Golden Set)이란?

- ① 모델이 학습할 때 사용한 원본 데이터셋
- ② 입력과 정답 쌍으로 이뤄진, 채점 기준이 되는 평가용 문제지
- ③ 모델이 절대 답하면 안 되는 금칙 사례 목록
- ④ 실제 사용자들의 질문 로그를 그대로 모아둔 것

[← 이전](#)

모듈 5 · RAG와 에이전트

[다음 →](#)

모듈 7 · AI 반도체 생태계 (심화)